

Servicio AtlasData

Gestor Documental y Arquitectura de Datos

Documento funcional de prueba para un sistema RAG

Version 1.0 | 10 de septiembre de 2026

Este documento es ficticio y se ha creado expresamente para probar recuperacion semantica, citas por pagina y respuestas basadas en contexto.

1. Objetivo y alcance

Objetivo

AtlasData es un servicio interno ficticio para centralizar documentacion tecnica y funcional de proyectos de datos. Su objetivo principal es permitir que arquitectos, responsables de servicio y analistas encuentren informacion fiable sin revisar manualmente decenas de documentos.

Alcance

El servicio cubre documentos PDF y DOCX relacionados con arquitectura, gobierno del dato, ingesta, calidad, seguridad y operacion. La primera version no procesa audio ni video. Los documentos escaneados requieren una fase adicional de OCR antes de ser indexados.

Usuarios

Los perfiles principales son Arquitecto de Datos, Data Engineer, Responsable de Servicio y Usuario de Negocio. Cada usuario solo puede consultar documentos para los que tenga permisos de lectura.

2. Arquitectura de la solucion

Vision general

La arquitectura se divide en cinco bloques: ingesta documental, procesamiento, almacenamiento, recuperacion y generacion. Los documentos se reciben, se extrae su texto, se dividen en fragmentos, se generan embeddings y se almacenan junto con sus metadatos.

Componentes

En el prototipo local se utiliza Python para la logica, PyMuPDF para extraer texto de PDF, sentence-transformers para generar embeddings y una busqueda por similitud coseno para recuperar fragmentos. En una evolucion posterior se podra utilizar Qdrant como base vectorial y un LLM local o remoto para generar respuestas.

Metadatos

Cada fragmento conserva como minimo el nombre del documento, numero de pagina, categoria documental, fecha de carga y nivel de confidencialidad. Estos metadatos permiten filtrar resultados y mostrar la fuente exacta utilizada en una respuesta.

3. Ingesta y procesamiento documental

Flujo de ingesta

Cuando se carga un documento, el sistema valida el formato y comprueba que no exista un fichero identico mediante un hash SHA-256. Si el documento es valido, se extrae el texto por pagina y se eliminan elementos repetitivos cuando sea posible, como encabezados y pies de pagina.

Chunking

El texto se divide inicialmente en fragmentos de 500 caracteres con un solape de 100 caracteres. El solape reduce la perdida de contexto cuando una idea queda dividida entre dos fragmentos. En una version avanzada, el chunking se realizara por secciones, parrafos y titulos en lugar de usar exclusivamente longitud fija.

Embeddings

Cada fragmento se transforma en un vector numerico de 384 dimensiones mediante el modelo paraphrase-multilingual-MiniLM-L12-v2. La misma transformacion se aplica a la pregunta del usuario para poder comparar semanticamente la consulta con los fragmentos del repositorio.

4. Recuperacion y respuestas

Busqueda semantica

La primera implementacion calcula la similitud coseno entre el embedding de la pregunta y todos los embeddings documentales. Se recuperan los tres fragmentos con mayor puntuacion. Una puntuacion alta indica mayor proximidad semantica, pero no garantiza por si sola que la respuesta sea correcta.

Generacion

Los fragmentos recuperados se incorporan al contexto enviado al modelo generativo. El modelo debe responder exclusivamente con la informacion incluida en ese contexto. Si los fragmentos no contienen la respuesta, debe indicar que no dispone de informacion suficiente.

Citas

Toda respuesta generada debe mostrar al menos el nombre del documento y la pagina de origen. Por ejemplo: Fuente: AtlasData_Arquitectura.pdf, pagina 7. Las citas permiten al usuario verificar la respuesta directamente en el documento original.

5. Seguridad y gobierno

Control de acceso

El acceso se aplica antes de realizar la recuperacion. Un usuario del area Comercial no debe recibir fragmentos de documentos clasificados exclusivamente para Riesgos, aunque semanticamente sean relevantes para su pregunta.

Confidencialidad

Los niveles definidos son Publico Interno, Confidencial y Restringido. Los documentos Restringidos requieren autorizacion explicita del propietario del dato. El sistema registra quien consulta un documento y cuando se produce el acceso.

Trazabilidad

Cada consulta genera un identificador unico y registra la pregunta, los documentos recuperados, las paginas utilizadas, la puntuacion de similitud y el modelo que genero la respuesta. Los logs se conservan durante 90 dias para auditoria del servicio.

6. Operacion y niveles de servicio

Disponibilidad

El objetivo de disponibilidad mensual del servicio es del 99,5 por ciento, excluyendo ventanas de mantenimiento previamente comunicadas.

Incidencias

Las incidencias de prioridad P1 tienen un tiempo objetivo de primera respuesta de 30 minutos y un objetivo de restauracion de 4 horas. Las incidencias P2 tienen primera respuesta en 2 horas y restauracion objetivo en 8 horas.

Carga documental

Un documento de hasta 50 MB debe quedar indexado en menos de 5 minutos en condiciones normales. Si el documento requiere OCR, el tiempo puede aumentar y el usuario vera el estado Procesando hasta que termine la indexacion.

7. Calidad y evaluacion del RAG

Conjunto de evaluacion

Antes de publicar una nueva version se ejecuta un conjunto minimo de 50 preguntas con respuesta conocida. Cada pregunta incluye la respuesta esperada y el documento que contiene la evidencia.

Metricas

Se evaluan Precision at K, Recall at K, relevancia del contexto, fidelidad de la respuesta y porcentaje de respuestas correctamente citadas. El objetivo inicial es alcanzar al menos un 90 por ciento de respuestas con una fuente correcta en el conjunto de validacion.

Mejora continua

Cuando una pregunta falla, se analiza por separado si el problema pertenece a extraccion, chunking, embeddings, retrieval, permisos o generacion. Esta separacion evita intentar corregir todos los fallos cambiando unicamente el prompt del modelo.

8. Caso de prueba: Proyecto Horizonte

Datos del proyecto

El Proyecto Horizonte es un caso ficticio de migración de datos desde sistemas on-premise a una plataforma cloud. La fecha prevista de inicio es el 15 de octubre de 2026 y la fecha objetivo de finalización es el 30 de junio de 2027.

Responsables

La responsable funcional del Proyecto Horizonte es Laura Martin. El responsable técnico es Daniel Vega. El comité de seguimiento se celebra cada martes a las 10:00.

Presupuesto y alcance

El presupuesto aprobado del Proyecto Horizonte es de 480.000 euros sin IVA. Incluye análisis de orígenes, diseño del modelo de datos, procesos de ingesta, validaciones de calidad y documentación operativa. No incluye la renovación de licencias de herramientas de terceros.

Criterios de aceptación

La migración se considera aceptada cuando el 100 por ciento de las tablas críticas se han cargado, no existen errores P1 abiertos y las validaciones de completitud y unicidad superan el 99,8 por ciento. La aprobación final corresponde al comité de seguimiento.

9. Resumen de datos concretos para pruebas

Dato	Valor
Disponibilidad mensual	99,5 %
P1 - primera respuesta	30 minutos
P1 - restauración	4 horas
Tamaño máximo objetivo	50 MB
Tiempo normal de indexación	Menos de 5 minutos
Retención de logs	90 días
Preguntas de evaluación	50
Objetivo de citas correctas	90 %
Proyecto de ejemplo	Proyecto Horizonte
Presupuesto	480.000 euros sin IVA
Inicio	15/10/2026
Fin objetivo	30/06/2027
Responsable funcional	Laura Martin
Responsable técnico	Daniel Vega

10. Preguntas sugeridas para probar el RAG

- ¿Cuál es el objetivo de AtlasData?
- ¿Qué herramientas se utilizan en el prototipo local?
- ¿Qué metadatos conserva cada fragmento?
- ¿Cómo se realiza el chunking inicial?

- ¿Cuántas dimensiones tienen los embeddings?
- ¿Que debe hacer el modelo si no encuentra información suficiente?
- ¿Cuánto tiempo se conservan los logs?
- ¿Cuál es el SLA de una incidencia P1?
- ¿Quién es la responsable funcional del Proyecto Horizonte?
- ¿Cuál es el presupuesto del Proyecto Horizonte?
- ¿Cuándo termina el Proyecto Horizonte?
- ¿Qué condiciones deben cumplirse para aceptar la migración?